

Detekcija Anomalija u Transakcijama

Isolation Forest algoritam za identifikaciju sumnjivih transakcija

Datum: 03.06.2026

1. Uvod i cilj projekta

Projektni zadatak bio je razviti model za detekciju anomalija u transakcijama. Cilj je identificirati neuobičajene transakcije koje mogu ukazivati na prijevare, greske u sustavu ili ekstremne obrasce kupnje. Problem koji rješavamo: tvrtke svakodnevno procesuiraju tisuće transakcija i teško je ručno identificirati sumnjive aktivnosti. Automatska detekcija anomalija omogućuje:

- Rano otkrivanje potencijalnih prijevara
- Smanjenje finansijskih gubitaka
- Povećanje sigurnosti poslovanja
- Automatizaciju revizijskih procesa

2. Podaci korišteni u analizi

Korišten je Superstore dataset koji sadrži 9.994 transakcije iz razdoblja 2014.-2017. Za svaku transakciju analizirane su sljedeće numeričke varijable (featurei):

- Sales (prodaja): ukupna vrijednost transakcije u EUR
- Quantity (kolicina): broj proizvoda u transakciji
- Discount (popust): postotak popusta na transakciju (0-0.80)
- Profit (profit): ostvareni profit od transakcije u EUR

Ove varijable odabrane su jer najbolje opisuju "normalno" ponašanje transakcija. Odstupanja u bilo kojoj od njih mogu ukazivati na anomaliju.

3. Metodologija

Koristene su dvije metode za detekciju anomalija: Isolation Forest i DBSCAN.

ISOLATION FOREST:

- Algoritam temeljen na stablima odlučivanja
- "Izolira" anomalije umjesto da modelira normalne podatke
- Anomalije su točke koje se lakše izoliraju (zahtijevaju manje rezova)
- Prednosti: brz, skalabilan, radi s visokodimenzionalnim podacima
- Parametri: contamination=0.05 (očekujemo 5% anomalija)

DBSCAN:

- Algoritam temeljen na gustoci podataka
- Grupira bliske točke, a izolirane točke označava kao anomalije (-1)

- Parametri: $\text{eps}=1.8$, $\text{min_samples}=5$
- Prednosti: ne zahtijeva unaprijed zadani broj grupa
- Nedostatak: osjetljiv na odabir parametara

ODABIR METODE:

Isolation Forest odabran je kao primarna metoda jer je robustniji i detektira poslovno značajne anomalije (visoke vrijednosti, visoki popusti). DBSCAN koristen je kao alternativa za usporedbu.

4. Vizualizacija 1: Anomalije u odnosu na prodaju i profit


Graf prikazuje transakcije u dva prostora:

LIJEVI GRAF (Sales vs Profit):

- Plave točke: normalne transakcije (koncentrirane oko niskih vrijednosti)
- Crvene točke: anomalije (raspršene, često s visokom prodajom)
- Anomalije često imaju ekstremno visoku prodaju (>5000 EUR)
- Neke anomalije imaju veliki negativni profit (gubitak)

DESNI GRAF (Quantity vs Discount):

- Anomalije često imaju visoku količinu (>5 komada)
- Anomalije često imaju visoki popust (>0.5 ili 50%)
- Kombinacija visoke količine i visokog popusta je rijetka



5. Vizualizacija 2: Usporedba distribucija (Normalno vs Anomalije)

Box plotovi prikazuju razlike između normalnih transakcija (1) i anomalija (-1):

SALES (prodaja):

- Normalne transakcije: medijan oko 50 EUR, većina ispod 200 EUR
- Anomalije: medijan oko 1.400 EUR, znatno veća prodaja

- Anomalije imaju 11 puta vecu prosjecnu prodaju

QUANTITY (kolicina):

- Normalne: vecina 1-3 komada
- Anomalije: cesto 5-10 komada


DISCOUNT (popust):

- Normalne: vecina nema popust ili ima mali popust (<20%)
- Anomalije: cesto visoki popusti (30-50%, cak i 80%)

PROFIT (profit):

- Normalne: vecinom pozitivan profit
- Anomalije: ekstremne vrijednosti (veliki profit ILI veliki gubitak)

Comparison: Normal vs Anomaly Transactions



6. Rezultati: Isolation Forest

Isolation Forest algoritam identificirao je 500 anomalija (5% svih transakcija).

TABLICA: Usporedba normalnih transakcija i anomalija

Metrika	Normalne	Anomalije	Omjer
Prosjecna prodaja (EUR)	151	1.723	11.4x
Prosjecna kolicina	3.6	6.6	1.8x
Prosjecni popust	14.8%	31.2%	2.1x
Prosjecni profit (EUR)	22	162	7.4x

TOP 5 NAJVECIH ANOMALIJA (najekstremnije):

1. 9.893 EUR prodaja, 0% popust, 4.946 EUR profit
2. 4.298 EUR prodaja, 40% popust, -1.862 EUR gubitak
3. 14.000 EUR prodaja, 0% popust, 6.720 EUR profit
4. 10.500 EUR prodaja, 0% popust, 5.040 EUR profit
5. 17.500 EUR prodaja, 0% popust, 8.400 EUR profit

7. Usporedba metoda: Isolation Forest vs DBSCAN


Kao alternativna metoda testiran je DBSCAN algoritam. Rezultati:

- DBSCAN je identificirao samo 29 anomalija (0.3% transakcija)
- Isolation Forest identificirao je 500 anomalija (5% transakcija)
- Sve DBSCAN anomalije (29) su također identificirane od strane Isolation Foresta
- Isolation Forest dodatno identificira 471 anomaliju koje DBSCAN propusta

ZASTO JE ISOLATION FOREST BOLJI?

1. DBSCAN detektira samo izolirane tocke, dok Isolation Forest nalazi i poslovno znacajne anomalije
2. Isolation Forest radi bolje s podacima koji imaju razlicite gustoce
3. Za poslovnu primjenu, 5% anomalija (500 transakcija) je realnije za reviziju nego 0.3% (29)

ZAKLJUCAK: Isolation Forest je preporucena metoda za detekciju anomalija u transakcijama.



8. Zaključak i preporuke

Projekt detekcije anomalija uspješno je proveden. Glavni nalazi:

1. 5% transakcija (500 od 9.994) označeno je kao anomalije
2. Anomalije imaju 11 puta veću prosječnu prodaju od normalnih transakcija
3. Anomalije imaju 2 puta veći prosječni popust (31% vs 15%)
4. Isolation Forest nadmasuje DBSCAN u detekciji poslovno značajnih anomalija

PREPORUKE ZA KLIJENTA:

1. Implementirati Isolation Forest model za automatsku detekciju sumnjivih transakcija
2. Postaviti prag osjetljivosti (contamination) prema željenoj razini revizije
3. Automatski označiti anomalije za dodatnu provjeru od strane revizorskog tima
4. Pratiti obrasce anomalija kroz vrijeme za identifikaciju potencijalnih prijevara
5. Integrirati model u postojeći sustav za obradu transakcija

9. Kontakt

Antoni Situm

Email: chisquare.analiza@gmail.com

CHI-SQUARE - Data Science za poduzeca

Usluge: Predviđanje prodaje, Segmentacija kupaca, Detekcija anomalija